



**BENEMÉRITA UNIVERSIDAD AUTÓNOMA DE PUEBLA
FACULTAD DE CIENCIAS FÍSICO MATEMÁTICAS
EXAMEN 4**

REPORTE EJECUTIVO

ANÁLISIS DE TRADES BURSÁTILES MEDIANTE MACHINE LEARNING

MATERIA: ANÁLISIS DE DATOS

PROFESOR: MTRO. DAVID NEXTICAPAN CORTES

INTEGRANTES:

- **ALEJANDRO VELASQUEZ VILLAVICENCIO.**
- **FABIOLA GUADALUPE CRUZ CASTELLANOS.**
 - **JUAN CARLOS PONCE DOMINGUEZ.**
- **RODRIGO NATANAEL ANGELES MENDOZA.**
 - **ELIAN FRANCO LOPEZ.**

ÍNDICE

INTRODUCCIÓN.	3
DESCRIPCIÓN DEL CONJUNTO DE DATOS.	3
VARIABLES PRINCIPALES.	3
LIMPIEZA Y PREPARACIÓN DE DATOS.	4
PRINCIPALES ACTIVIDADES REALIZADAS.	4
<i>Conversión de variables categóricas.</i>	4
<i>Variables temporales.</i>	4
<i>Detección de leakage.</i>	4
<i>Transformación logarítmica.</i>	5
<i>Eliminación de multicolinealidad.</i>	5
<i>Escalamiento.</i>	5
ANÁLISIS EXPLORATORIO DE DATOS (EDA).	5
DISTRIBUCIÓN DE CLASES.	5
HALLAZGOS IMPORTANTES.	6
<i>Franja horaria.</i>	6
<i>Dirección de operación.</i>	6
<i>Volumen monetario.</i>	6
<i>Relaciones entre variables.</i>	6
DIVISIÓN TRAIN/TEST.	6
MODELO DE REGRESIÓN LOGÍSTICA.	7
CARACTERÍSTICAS PRINCIPALES.	7
RESULTADOS	7
INTERPRETACIÓN.	7
MODELO SVM (MÁQUINAS DE SOPORTE VECTORIAL).	7
CARACTERÍSTICAS.	7
RESULTADOS.	8
INTERPRETACIÓN.	8
ÁRBOL DE DECISIÓN.	8
RESULTADOS	8
INTERPRETACIÓN.	9
MODELO RANDOM FOREST.	9
RESULTADOS.	9
INTERPRETACIÓN.	9
COMPARACIÓN FINAL DE MODELOS.	10
SELECCIÓN DEL MEJOR MODELO.	10
JUSTIFICACIÓN.	10
CONCLUSIONES.	10
RECOMENDACIONES.	11

Introducción.

El presente proyecto tiene como objetivo desarrollar y comparar distintos modelos de clasificación supervisada para predecir el resultado de operaciones bursátiles (trades) utilizando técnicas de Machine Learning en R.

Se implementaron y evaluaron cuatro enfoques principales:

- Regresión Logística.
- Máquinas de Soporte Vectorial (SVM).
- Árboles de Decisión.
- Bosques Aleatorios (Random Forest).

El propósito principal fue identificar qué modelo ofrece el mejor desempeño predictivo para clasificar operaciones ganadoras y perdedoras, considerando métricas como accuracy, sensibilidad, especificidad, AUC y balanced accuracy.

Descripción del conjunto de datos.

La base de datos utilizada contiene información histórica de operaciones bursátiles reales, incluyendo variables financieras, temporales y operativas relacionadas con cada trade.

Variables principales.

Entre las variables más relevantes destacan:

- **Simbolo:** activo bursátil operado.
- **Cantidad:** volumen de acciones negociadas.
- **Precio_Transaccion:** precio de ejecución del trade.
- **Precio_Cierre:** precio de cierre del activo.
- **Direccion:** tipo de posición (Long o Short).
- **Volumen_Monetario:** tamaño económico de la operación.
- **Dia_Semana:** día en que se realizó el trade.
- **Franja_Horaria:** momento del mercado donde ocurrió la operación.
- **Target:** variable objetivo, donde:
 - 0 = trade perdedor
 - 1 = trade ganador

El dataset presentó aproximadamente 5,700 observaciones después del procesamiento inicial.

Limpieza y preparación de datos.

Para garantizar la calidad estadística y evitar sesgos en el modelado, se realizó un proceso de limpieza y transformación de datos.

Principales actividades realizadas.

Conversión de variables categóricas.

Variables como:

- Simbolo
- Direccion
- Franja_Horaria
- Dia_Semana

fueron convertidas a formato factor para permitir su utilización correcta en los modelos supervisados.

Variables temporales.

La variable original de fecha fue descompuesta en:

- Mes
- Día
- Hora
- Minuto

Esto permitió capturar patrones temporales relevantes sin utilizar directamente la fecha completa.

Detección de leakage.

Se identificaron variables con fuga de información:

- Basico
- Diferencia_Cierre
- Diferencia_Porc

Estas variables fueron eliminadas debido a que contenían información directamente relacionada con el resultado final del trade, lo cual podía generar sobreajuste y resultados artificialmente elevados.

Transformación logarítmica.

La variable Volumen_Monetario presentó alta asimetría y valores extremos, por lo que se aplicó:

$\log_{10}(\text{Volumen Monetario})$

Esta transformación estabilizó la distribución y redujo el impacto de outliers.

Eliminación de multicolinealidad.

Se detectó alta correlación entre:

- Precio_Transaccion
- Precio_Cierre

Por ello se eliminó Precio_Cierre para evitar redundancia de información.

Escalamiento.

Las variables numéricas fueron estandarizadas usando centramiento y escalamiento exclusivamente con datos de entrenamiento, evitando data leakage.

Análisis Exploratorio de Datos (EDA).

El análisis exploratorio permitió identificar patrones importantes dentro del comportamiento de los trades.

Distribución de clases.

Se observó un desbalance moderado:

- Aproximadamente 68-70% trades perdedores.
- Aproximadamente 30-32% trades ganadores.

Aunque existe desbalance, no fue lo suficientemente severo para requerir técnicas avanzadas de rebalanceo.

Hallazgos importantes.

Franja horaria.

La mayoría de las operaciones se concentraron durante:

- Apertura
- Media sesión

lo cual coincide con los periodos de mayor liquidez del mercado.

Dirección de operación.

Se observó una distribución relativamente equilibrada entre posiciones:

- Long
- Short

Volumen monetario.

El volumen monetario presentó alta dispersión y valores extremos, característica común en mercados financieros reales.

Relaciones entre variables.

Las matrices de correlación y gráficos de dispersión permitieron detectar relaciones fuertes entre variables financieras, justificando la eliminación de variables redundantes.

División Train/Test.

Se utilizó una división temporal del dataset:

- 80% entrenamiento
- 20% prueba

La separación se realizó respetando el orden cronológico de las operaciones para simular un escenario financiero real y evitar fuga temporal de información.

Modelo de Regresión Logística.

La regresión logística fue utilizada como modelo base de clasificación binaria.

Características principales

- Modelo interpretable
- Fácil análisis estadístico
- Buena capacidad de generalización

Resultados

Métrica	Valor
Accuracy	73.73%
Sensibilidad	65.05%
Especificidad	92.08%
Balanced Accuracy	78.57%
Kappa	0.4866
AUC	0.7668

Interpretación.

La regresión logística obtuvo el mejor desempeño global entre todos los modelos evaluados. Destacó especialmente por su alta especificidad y su adecuado equilibrio entre métricas.

Además, presentó buena interpretabilidad, permitiendo comprender el efecto de las variables sobre la probabilidad de éxito del trade.

Modelo SVM (Máquinas de Soporte Vectorial).

Se implementaron distintos modelos SVM, incluyendo kernels lineales y no lineales.

Características.

Los modelos SVM permiten proyectar la información hacia espacios de mayor dimensionalidad, facilitando la separación entre clases incluso cuando no existe separación lineal en el espacio original.

Resultados.

Métrica Valor

Accuracy 70.87%

Sensibilidad 65.21%

Especificidad 82.84%

Balanced Accuracy 74.02%

Kappa 0.4183

AUC 0.7555

Interpretación.

El modelo SVM mostró un desempeño competitivo y un buen poder predictivo. Sin embargo, presentó menor interpretabilidad en comparación con la regresión logística debido a la complejidad geométrica del hiperplano en espacios multidimensionales.

Árbol de Decisión.

Se implementaron árboles utilizando:

- Índice Gini
- Ganancia de información
- MaxDepth
- Poda mediante validación cruzada

Resultados

Métrica	Valor
Accuracy	67.06%
Sensibilidad	64.74%
Especificidad	71.95%
Balanced Accuracy	68.34%
AUC	0.7007

Interpretación.

El árbol de decisión fue el modelo más interpretable visualmente, permitiendo comprender fácilmente las reglas de clasificación y la lógica de decisión.

Sin embargo, presentó menor desempeño predictivo respecto a modelos más complejos.

La poda mediante parámetro cp permitió reducir sobreajuste y mejorar capacidad de generalización.

Modelo Random Forest.

Se implementaron modelos Random Forest con:

- 500 árboles
- Ajuste de hiperparámetros
- Modificación de nodesize

Resultados.

Métrica	Valor
Accuracy	68.43%
Sensibilidad	23.76%
Especificidad	89.55%
Balanced Accuracy	56.78%
Kappa	0.1553
AUC	0.7551

Interpretación.

Aunque el modelo obtuvo un AUC relativamente alto, presentó un fuerte sesgo hacia la clase negativa.

La sensibilidad fue considerablemente baja, indicando dificultad para detectar trades ganadores.

Esto sugiere que el modelo aprendió principalmente patrones asociados a trades perdedores debido al desbalance de clases.

Comparación Final de Modelos.

Modelo	Accuracy	AUC	Balanced Accuracy	Interpretabilidad
Regresión Logística	73.73%	0.7668	78.57%	Alta
SVM	70.87%	0.7555	74.02%	Baja
Árbol de Decisión	67.06%	0.7007	68.34%	Muy Alta
Random Forest	68.43%	0.7551	56.78%	Media

Selección del Mejor Modelo.

El modelo seleccionado como mejor alternativa fue la **Regresión Logística**.

Justificación.

- Mayor accuracy general.
- Mejor balanced accuracy.
- Mayor AUC.
- Buen equilibrio entre sensibilidad y especificidad.
- Alta interpretabilidad.
- Menor complejidad computacional.

Aunque SVM mostró resultados competitivos, la regresión logística ofreció un mejor balance entre desempeño y facilidad de interpretación, aspecto importante en aplicaciones financieras.

Conclusiones.

El proyecto permitió comparar distintos enfoques de Machine Learning aplicados al análisis de trades bursátiles.

Los resultados mostraron que:

- El preprocesamiento y eliminación de leakage fueron fundamentales para obtener modelos válidos.

- Las variables temporales y operativas aportaron capacidad predictiva importante.
- Los modelos más complejos no necesariamente ofrecieron mejores resultados.
- La regresión logística logró el mejor equilibrio entre desempeño y estabilidad.

Finalmente, se concluye que el uso de Machine Learning puede apoyar significativamente la toma de decisiones financieras, siempre que exista una preparación adecuada de datos y una correcta validación estadística.

Recomendaciones.

Para trabajos futuros análisis las recomendaciones en base a este trabajo podrían ser:

- Aplicar técnicas de balanceo de clases (SMOTE, undersampling).
- Incorporar variables macroeconómicas y técnicas.
- Evaluar modelos boosting como XGBoost o LightGBM.
- Implementar validación temporal rolling window.
- Realizar optimización más avanzada de hiperparámetros.